

Capstone Projekt

Wie gut lässt sich BIP-Wachstum wirklich vorhersagen?

Ein globaler Methodenvergleich zur BIP-Wachstumsprognose mit SARIMAX, TFT & Chronos-2

Antoine Hunou · **Marius Riesle** · **Deborah Lang**


AI for Business Prognosis · Prof. Dr. Carsten Lanquillon



24.07.2026

Agenda

- 1 Problemstellung & Zielsetzung
- 2 Datengrundlage & -aufbereitung
- 3 Evaluation:
Metriken & Backtesting
- 4 Modellauswahl & Vorgehen
- 5 Modellergebnisse:
SARIMAX · TFT · Chronos-2
- 6 Modellvergleich
- 7 Fazit & Ausblick






1 Problemstellung & Zielsetzung

Ziel reales BIP-Wachstum
von 116 Ländern & für 1–5 Jahre

 **Business Use-Case:**
mittelfristige
Fiskal-, Investitions- & Kapitalallokationsplanung

 **Challenges:**
✓ Long / Multi-Horizon
✓ Unsicherheitsbewertung
✓ Multivariat / Multi-Series
✓ Exogene Treiber

 **Risiken:**
Strukturbrüche
Länderfilter
Wirtschaftliche Zusammenhänge



*Krisen 2009 und 2020 als starke Einbrüche
→ genau das macht mittelfristige Prognosen schwer*

Erfolg ≠ perfekte Punktprognoze
Sondern:

- MASE-Vorteil ggü. Random Walk & statistisch abgesichert
- Kalibrierte 80%-Unsicherheitsintervalle
- Gepoolt über alle 116 Länder & Folds inkl. COVID-Holdout



2 Datengrundlage & -aufbereitung

Ziel reales BIP-Wachstum



Quelle: World Bank WDI
 Zeitraum: 1960 – 2024
 Qualitätsfilterung: Von 217 auf 116 Länder reduziert


Exogene Treiber
 (zeitveränderlich):

Demografie, Konvergenz,
 Investitionen, Handel &
 Inflation

Statische Ländermerkmale
 (zeitunveränderlich):

Region,
 Einkommensgruppe


BIP-Wachstum kaum Eigendynamik:
 Median AR(1) $\approx 0,27$
 → exogene Treiber sind nötig





Datengrundlage: BIP-Entwicklung

BIP-Entwicklung der Länder — BIP pro Kopf vs. Erwerbsanteil, Blasengröße = Bevölkerung






3 Evaluation: Metriken & Backtesting

Metriken

	Primärmetrik	MASE skalenfrei & vergleichbar über alle Länder
	Nebenmetriken	RMSE/ MAE für Punktfehler
	Signifikanz	Wilcoxon-Test gepoolt über alle Land-Origin-Paare
	Vergleich	naive Random-Walk-Baseline

Backtesting

- Walk-Forward mit expandierendem Fenster



Fünf Trainingsstände (1999–2019)
je 5-Jahres-Test

- Finaler Holdout schwer,
da COVID enthält



4 Modellauswahl & Vorgehen

BASELINE

Random Walk + Drift



Fortschreibung
+ mittleren Trend

- kein Training
- keine Kovariaten

—

KLASSISCHE METHODE

SARIMAX



Zeitreihenmodell je Land
mit Demografie als Exogene

- ✓ interpretierbare Koeffizienten
für Fiskalplanung

Bekannt

DEEP LEARNING METHODE

TFT



EIN global trainiertes Modell

Multi-Horizon
Unsicherheitsbewertung
Exogene Variablen

- ✓ Challenges abdecken

NEU

ZERO-SHOT-BENCHMARK

Chronos-2



Vortrainiertes Modell

Zero-shot
In-Context-Learning



- ✓ Benchmark
ohne Trainingsaufwand

NEU



5 Modellergebnis: SARIMAX

- › **Ein Modell je Land** mit exogene Demografie-Daten
- › **Vorgehen:** ARIMA -> SARIMA -> SARIMAX
 - › Frage: Was für eine Saisonalität haben jährliche Daten?



Takeaways

- Wir testen mit 5, 7 und 9 Jahren Zykluslänge
- Saisonalitätskomponente ist nutzlos




5 Modellergebnis: SARIMAX


X: Erweiterung um exogene Variablen

Variablenwahl

- ☐ Multihorizontprognosen mit Autoregressivem Modell
- 💡 Könnten im voraus bekannte exogene Variablen einen Mehrwert bieten?
 - ORACLE Modelle mit Leakage



Modellgüte



ex ante = im voraus bekannte Variablen

■ = Oracle Modelle, Leakage



5 Modellergebnis: SARIMAX



Ergebnis

ARIMA schlägt komplexere Modelle



Geringe Datenmenge


Exogene Variablen machen Modell instabil




Varianzheterogenität

Muster im mittleren Fehler der Residuen erkennbar

Modellgüte



Residualanalyse







5 Modellergebnis: Temporal Fusion Transformer

Ansatz: EIN globales Modell über alle 116 Länder
mit statischen, bekannt-zukünftige & beobachtete Variablen

- › **Bester Fold:** Origin 2014, MASE 0,61
- › **Schwächster Fold:** finaler COVID-Holdout, MASE 1,30
– Abdeckung bricht auf 48,8 % ein

- › **Kalibrierung:** über alle Folds nur 67 % statt 80 % Abdeckung
→ Modell tendenziell überkonfident






5 Modellergebnis: Temporal Fusion Transformer

Interpretierbarkeit & Grenzen

- › *region & income_group* dominieren die Variable **Importance**
- › Prognosen streuen nur halb so stark wie die Relaität
 - › 2,3 gegen 5,2 pp
- › Keine sich kreuzenden **Quantile** (0 von 2900)
 - › Notwendige, aber keine hinreichende Bedingung für gute Kalibrierung
- › **Grenze:** Punktprognose bleibt über den 5-Jahres-Horizont auffällig flach – reagiert schwächer auf Extremereignisse als der reale Verlauf







5 Modellergebnis: Chronos-2

- › **„Normale“** Jahre werden ordentlich prognostiziert
- › Bei **Krisen** versagt das Modell
- › **Ergebnis:** Kaum besser als das historische Mittel
- › **Kovariaten:** Exogene Treiber bringen keinen nachweisbaren Vorteil

Länderebene:
Nur ~3% besser als
historisches Mittel



Beispiel Deutschland (ruhiger Fold 2015–2019): Prognose + 80 %-Band.




Beispiel USA (Fold mit Corona Krise): Prognose + 80 %-Band.



5 Modellergebnis: Chronos-2

- › Einzelne Länder 5 Jahre vorherzusagen ist fast unmöglich
- › Lösung: **Alle Länder** zur Weltreihe zusammenfassen
 - › Weltreihe schwank weniger, das Modell wird nicht besser



Weltaggregat (schwarz) gegen die 10.-90.-Perzentil-Streuung der 116 Länder – nur 2009 & 2020 als markante Einbrüche.

Aggregation:
 Einzelne Länder: MAE 3,1 pp
 Weltreihe: MAE 1,25 pp


**Fehler ×2,5 kleiner
 Kein Vorsprung
 gegenüber Mittelwert**



5 Modellergebnis: Chronos-2

- › Auch auf dem **Aggregat** schlägt Chronos-2 den simplen historischen Mittelwert nicht
- › Im **Krisenjahr** gewinnt der Mittelwert sogar klar – flache Prognosen verpassen die Ausschläge
 - › **Chronos-2 reproduziert im Wesentlichen nur den langfristigen Durchschnitt – kein echter Mehrwert**

Weltebene: Chronos-2 liegt gleichauf mit dem simplen Mittelwert



Weltebene: MAE über alle Folds – Chronos-2 auf Augenhöhe mit dem historischen Mittel, beide weit besser als der Random Walk.

Top-Down:



116 Länder → Weltreihe → 1 Prognose

Bottom-Up:


116 Länder → 116 Prognosen → Summe = Weltprognose



Modellvergleich




	Modell	MASE	RMSE	Cov. 80%
●	Random Walk	1.08	6.87	—
●	(S)ARIMA(X)	0.84	5.34	—
●	TFT	0.92	5.55	0.67
●	Chronos-2	0.85	5.45	0.84





6 Modellvergleich

Modell	Ø Rang	Siege	Siegrate	Avg MASE	p-Wert vs Baseline
 Chronos	2.05	148	25.5 %	0.85	< 0.001
 (S)ARIMA(X)	2.09	157	27.1 %	0.84	< 0.001
 TFT	2.54	148	25.5 %	0.92	< 0.001
Baseline	3.31	127	21.9 %	1.08	< 0.001






6 Modellvergleich

MASE nach World-Bank-Region

East Asia & Pacific	1.11	0.88	0.97	0.89
Europe & Central Asia	1.44	1.04	1.19	1.08
Latin America & Caribbean	1.28	0.92	1.05	1.02
Middle East, North Africa	0.79	0.66	0.68	0.66
North America	1.39	0.84	0.76	0.76
South Asia	0.80	0.80	0.87	0.72
Sub-Saharan Africa	0.75	0.65	0.66	0.58
	Baseline	ARIMA	TFT	Chronos-2

MASE nach Einkommensgruppe

High income	1.28	0.95	1.04	0.97
Low income	0.79	0.63	0.72	0.60
Lower middle income	0.69	0.64	0.74	0.62
Upper middle income	1.24	0.92	0.96	0.95
	Baseline	ARIMA	TFT	Chronos-2





Fazit

&

Ausblick



Herausforderndes Problem

BIPs sind schwierig vorherzusagen



Geringe Datenmengen

1960 – 2024 (Abzüglich Test und Validierungsfenster)



Stärksten Modelle

ARIMA und Chronos



Nicht praxistauglich

Modelle schlagen Baseline nur knapp



Quartalsdaten statt
jährlichen Daten

Andere / zusätzliche
exogene Variablen

Alternative
Aggregationsverfahren

Multi-Country and Multi-Horizon GDP Forecasting Using Temporal Fusion Transformers - [Laborda et al.](#)