

N-BEATS

Deep Learning Methoden für
Business Prognosis

Von Antoine Hunou, Deborah Lang
und Marius Riesle

Am 10. Juli 2026



Gliederung

1. Motivation & Grundidee von N-BEATS
2. Architektur
3. Mathematischer Hintergrund
4. Warum funktioniert das? Residual Learning
5. Generic vs. Interpretable N-BEATS
6. Erweiterung N-BEATSx
7. Vor-, Nachteile & Business Use Cases



Von klassischen Forecasting-Modellen zu Deep Learning



Bisher: Klassische Methoden

z.B. ETS, (S)ARIMA(X), Prophet, STL



Modellstruktur explizit definiert



Modellannahmen



meist ein Modell pro Zeitreihe



Problem mit vielen exogenen Variablen & Nichtlinearitäten



Heute: DL-Methoden



lernt Struktur selbst



keine Zeitreihen-spezifischen Annahmen



End-to-End Learning



Probleme klassischen Zeitreihen-Forecasts überwinden

N-BEATS = Neural Basis Expansion Analysis for Interpretable Time Series Forecasting

Für univariates Forecasting reichen klassische Feedforward-Netze völlig aus.

~ Oreshkin et al. im Jahr 2020

Was ist die Grundidee von N-BEATS?



N-BEATS = Neural Basis Expansion Analysis for Interpretable Time Series Forecasting

Für univariates Forecasting reichen klassische Feedforward-Netze völlig aus.

~ Oreshkin et al. im Jahr 2020



Schrittweise Konstruktion des Forecasts

und finale Vorhersage entsteht durch Addition aller Teilvorhersagen

Ziele von N-BEATS



Einfaches, allgemeines & trotzdem aussagekräftiges Modell



kein zeitserienspezifisches Feature Engineering & Input-Skalierung



Interpretierbarkeit für Forschung


Wie wird N-BEATS architektonisch umgesetzt?



- Input:
Lookback Window
- Aufbau:
 - Gesamtarchitektur
 - Stack
 - Basic Block

- Outputs:
 1. Backcast
 2. Forecast

- Hierarchische Forecast-Zerlegung
- Double Residual Connections



Wie lässt sich N-BEATS mathematically beschreiben?



- x_ℓ Input-Vektor

Fully Connected Layers mit RELU-Aktivierung

$$h_{\ell,1} = \text{FC}_{\ell,1}(x_\ell) = \text{RELU}(W_{\ell,1}x_\ell + b_{\ell,1})$$

$$h_{\ell,2} = \text{FC}_{\ell,2}(h_{\ell,1}) = \text{RELU}(W_{\ell,2}h_{\ell,1} + b_{\ell,2})$$


- $W_{\ell,i}$ Gewichtsmatrix
- $b_{\ell,i}$ Bias

Expansionskoeffizient

$$\theta_\ell^b = \text{LINEAR}_\ell^b(h_{\ell,4}) = W_\ell^b h_{\ell,4}$$

$$\theta_\ell^f = \text{LINEAR}_\ell^f(h_{\ell,4}) = W_\ell^f h_{\ell,4}$$

LINEAR() ist einfache lineare Projektion



Basisfunktion bzw. -vektoren

$$\widehat{y}_\ell = g_\ell^f(\theta_\ell^f) = \sum_{i=1}^{\dim(\theta_\ell^f)} \theta_{\ell,i}^f v_i^f$$

$$\& \widehat{y} = \sum_\ell \widehat{y}_\ell$$

→ Forecast Aggregation über alle Blöcke

$$\widehat{x}_\ell = g_\ell^b(\theta_\ell^b) = \sum_{i=1}^{\dim(\theta_\ell^b)} \theta_{\ell,i}^b v_i^b$$


$$\& x_\ell = x_{\ell-1} - \widehat{x}_{\ell-1}$$

Varianten für die Basisfunktionen:
Generic & Interpretable

- Output-Vektoren $\widehat{x}_\ell$ & $\widehat{y}_\ell$

→ Jeder Block modelliert einen Teil des Eingangsignals (Backcast) & liefert gleichzeitig einen Teil der Gesamtvorhersage (Forecast)

Verbessert Residual Learning die Forecasting-Qualität?



Verbesserungen

- ⚙ Vereinfachte Optimierung
- ↺ Gradient Flow
- 🧱 Hierarchische Forecast-Zerlegung
→ jede Approximation wird kleiner
- 🔍 Interpretierbarkeit

Wie entsteht Interpretierbarkeit in N-BEATS?





Generic N-Beats

- Black Box
- Lernt optimale Basisfunktionen

→ Data-driven Learning




- + Maximale Genauigkeit
- keine erkennbaren Strukturen der Basisfunktionen



Interpretable N-Beats

- Inductive Bias
- Definierte Basisfunktionen
Trends: Polynom-Basis
Saisonalität: Fourier-Basis
→ Knowledge-driven Learning

- Genauigkeit geringfügig verschlechtert
- + Hohe Interpretierbarkeit




Wie integriert N-BEATSx externe Einflussgrößen?



- Erweiterung um exogene Variablen
- Grundidee identisch und zusätzlich
 - Input X
 - Stack S

- **Interpretable Variante**
mit Basis X
- **Generic Variante**
TCN um aus X Kontextvektor zu lernen

→ Verbesserung der Prognose durch Zusätzliche Informationen



Wann lohnt sich der Einsatz von N-BEATS?



Stärken

- 💪 Einfache Architektur
- 💪 Hohe Forecast Accuracy
- 💪 Kein Feature Engineering
- 💪 Gute Generalisierung
- 💪 Optional interpretierbar



Grenzen

- ⚠️ Nur univariate Forecasts
- ⚠️ Kein probabilistischer Forecast
- ⚠️ Große Datenmenge nötig
- ⚠️ exogene Variablen nur in N-BEATSx
- ⚠️ Mittlerweile durch neuere Modelle teilweise überholt



Business Use-Cases

- 🛒 Retail & Demand Forecasting
- ⚡ Energieversorgung
- 📊 Sales Forecasting
- 🔗 Supply Chain
- 💰 Finance

Wurden die Autoren Ihrer Aussage gerecht?

N-BEATS = Neural Basis Expansion Analysis for Interpretable Time Series Forecasting

Für univariates Forecasting reichen klassische Feedforward-Netze völlig aus.

~ Oreshkin et al. im Jahr 2020

2020



Ja



Empirisch bestätigt



State-of-the-Art



Einfache Architektur

vs.

Heute



Ja, aber ...



Nur unter bestimmten Voraussetzungen




Neuere Modelle wie TFT, Chronos, etc.



Meilenstein in der Forecasting-Forschung

Live Demo



Quellen

- B. N. Oreshkin, D. Carпов, N. Chapados, and Y. Bengio, "N-BEATS: Neural basis expansion analysis for interpretable time series forecasting," in *Proceedings of the International Conference on Learning Representations (ICLR)*, 2020.
arXiv:1905.10437.
<https://doi.org/10.48550/arXiv.1905.10437>
- K. G. Olivares, C. Challu, G. Marcjasz, R. Weron, and A. Dubrawski, "Neural basis expansion analysis with exogenous variables: Forecasting electricity prices with NBEATSx," *International Journal of Forecasting*, vol. 38, no. 4, pp. 1469–1484, 2022.
<https://doi.org/10.1016/j.ijforecast.2022.03.001>
- S. Makridakis, E. Spiliotis, and V. Assimakopoulos, "The M4 Competition: 100,000 time series and 61 forecasting methods," *International Journal of Forecasting*, 2020.
<https://doi.org/10.1016/j.ijforecast.2019.04.014>
- K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Las Vegas, NV, USA, 2016.
<https://doi.org/10.1109/CVPR.2016.90>
- I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016.
<https://www.deeplearningbook.org>
- R. J. Hyndman and G. Athanasopoulos, *Forecasting: Principles and Practice*, 3rd ed. Melbourne, Australia: OTexts, 2021.
<https://otexts.com/fpp3>